

Proyecto:
Análisis Avanzado de Datos
para el sistema judicial
de EE. UU.

Máster en Data Analytics

LUIS HERMÓGENES - EDUARDO CONDE



ÍNDICE

1. INTRODUCCIÓN.....	3
2. HERRAMIENTAS Y ENTORNO DE TRABAJO.....	4
3. DESCRIPCIÓN DE LOS DATOS.....	5
3.1. EXPLORACIÓN INICIAL.....	5
3.1.1. compass_score_raw.....	5
3.1.2 compass-scores-two-years	8
3.2. LIMPIEZA DE DATOS	13
3.2.1. compass_score_raw.....	14
3.2.2. compass_score_two_years	16
4. DETECCIÓN DE SESGOS.....	19
5. EVALUACIÓN DE LOS PUNTAJES DE COMPAS.....	25
5.1. AUC.....	26
5.2. PRECISION/RECALL	30
5.3. CALIBRATION.....	34
5.4. CONCLUSIÓN DE LA EVALUACIÓN	35
6. CREACIÓN DEL MODELO DE MACHINE LEARNING.....	37
6.1. Estructura.....	37
6.2. Modelo original	37
6.2.1. Preparación del dataset.....	37
6.2.2. Entrenamiento del modelo.....	38
6.2.3. Comparación entre test y training, usando classification reports.	39
6.3. Modelo balanceado.....	41
6.4. Modelo original vs Modelo balanceado	42
¿Qué nos dicen estos datos?	43
CONCLUSIÓN DE LA EVALUACIÓN DE AMBOS MODELOS	43
7. MODELO COMPAS VS NUESTRO MODELO.....	44
7.1. AUC.....	44
7.2. CALIBRATION.....	46
COMPARACIÓN DE CALIBRATION DE COMPAS CON NUESTRO MODELO.....	47
COMPARACIÓN DEL MODELO COMPAS Y EL NUESTRO SOBRE LA CALIBRATION POR RAZAS.....	47
7.3. RESTO DE MÉTRICAS.....	48
7.4. Evaluación de métricas globales de equidad por raza.....	49

7.5.	Equilized Odds gap	52
8.	DASHBOARD DE MONITORIZACIÓN	53
8.1.	Arquitectura y pipeline de datos.....	53
8.2.	Contenido del dashboard.....	53
	Página 1: Métricas de rendimiento y equidad (interactiva)	54
	Página 2: rendimiento y calibración (estática).	54
9.	CONCLUSIONES Y REFLEXIONES	55
	Resultados numéricos entre modelos	55
	Limitaciones	55
	Reflexión crítica: implicaciones del uso de modelos predictivos en decisiones judiciales ..	56
10.	BIBLIOGRAFÍA.....	57

1. INTRODUCCIÓN

En la última década, la administración de justicia en los Estados Unidos ha experimentado una transformación digital sin precedentes. Ante la saturación de los tribunales y la búsqueda de una mayor objetividad en la toma de decisiones, diversas jurisdicciones comenzaron a adoptar herramientas de evaluación de riesgos automatizadas. El condado de Broward, en Florida, se convirtió en uno de los escenarios principales para esta implementación al adoptar el sistema COMPAS (*Correctional Offender Management Profiling for Alternative Sanctions*).

La premisa original era ambiciosa y, en apariencia, loable: utilizar modelos estadísticos para predecir la probabilidad de que un detenido volviera a cometer un delito (reincidencia) en un periodo determinado. Estas puntuaciones de riesgo no solo pretendían ayudar a los jueces a decidir sobre la libertad bajo fianza o la duración de las condenas, sino también optimizar los recursos penitenciarios y de rehabilitación. Se confiaba en que un algoritmo, al alimentarse de datos históricos, estaría libre de los prejuicios cognitivos y sesgos subjetivos inherentes a la condición humana.

Sin embargo, la percepción de neutralidad de estos sistemas fue puesta en tela de juicio en mayo de 2016. Tras dos años de recopilación y seguimiento de datos de más de 7.000 detenidos evaluados por COMPAS en el condado de Broward, el medio de investigación ProPublica publicó un informe que sacudió los cimientos del Derecho Penal moderno.

El estudio reveló una disparidad alarmante en el desempeño del algoritmo según la raza del individuo. Los datos demostraron que la puntuación de riesgo fallaba de manera asimétrica: los acusados afroamericanos tenían el doble de probabilidades de ser clasificados erróneamente como de "alto riesgo" (falsos positivos) sin haber reincidido posteriormente. En contraste, los acusados blancos eran clasificados con mayor frecuencia como de "bajo riesgo" (falsos negativos) a pesar de haber vuelto a delinquir en los dos años siguientes.

Este hallazgo no solo cuestionó la validez técnica de COMPAS, sino que abrió un debate ético sobre la equidad algorítmica (*algorithmic fairness*). La controversia se intensificó cuando Northpointe (la empresa desarrolladora) defendió su modelo alegando que el sistema mantenía la "calibración predictiva", lo que puso de manifiesto que existen múltiples definiciones matemáticas de justicia que, a menudo, son incompatibles entre sí.

La presente memoria surge de la necesidad de ir más allá de la mera observación de estos sesgos. Si bien el estudio de ProPublica fue pionero, la comunidad académica ha identificado posteriormente áreas de mejora en el tratamiento de sus datos, como inconsistencias en los intervalos temporales de observación y la selección de variables predictoras.

La motivación central de este trabajo es realizar un análisis exhaustivo del proceso de generación de estas puntuaciones de riesgo y, mediante técnicas avanzadas de Ciencia de Datos, proponer un modelo de Machine Learning que supere las limitaciones éticas detectadas. No se trata simplemente de predecir la reincidencia con mayor exactitud, sino de hacerlo bajo un marco de Justicia Distributiva.

Para abordar este desafío, el proyecto se estructura en tres fases críticas:

1. Auditoría y Descomposición del Modelo COMPAS: Analizaremos las variables originales (antecedentes juveniles, recuento de delitos previos, edad) para entender cómo el algoritmo construye su predicción. Evaluaremos de forma crítica si el "Decile Score" actual cumple con los estándares mínimos de equidad en las subpoblaciones analizadas.
2. Identificación de Variables Significativas y Sesgadas: Investigaremos qué variables actúan como indicadores indirectos (*proxies*) de la raza. El objetivo es realizar una limpieza de datos técnica que elimine el ruido administrativo e histórico que perpetúa la discriminación, centrándonos en aquellos factores que realmente poseen una correlación legítima con la reincidencia.
3. Desarrollo de un Modelo de Machine Learning Mejorado: Mediante la implementación de algoritmos de clasificación, buscaremos entrenar un modelo que no solo iguale la precisión de COMPAS, sino que reduzca drásticamente la brecha en las tasas de falsos positivos entre grupos étnicos.

En conclusión, este TFM busca demostrar que la tecnología no es una entidad autónoma ajena a la ética. A través del análisis del caso de Broward, pretendemos aportar una metodología de desarrollo de modelos más transparente, justa y técnicamente robusta, contribuyendo así al campo emergente de la Inteligencia Artificial responsable.

2. HERRAMIENTAS Y ENTORNO DE TRABAJO

El desarrollo del proyecto se apoyó en las siguientes herramientas: Google Colab y Visual Studio Code como entornos de desarrollo para la escritura y ejecución del código Python; Microsoft Office para la redacción de la memoria, documentación escrita y presentación final; Google Meet para la coordinación y reuniones del equipo; y Looker Studio conectado a Google BigQuery para la construcción del dashboard interactivo, donde BigQuery sirvió como capa de almacenamiento y transformación de los datos exportados desde el notebook.

El control de versiones del notebook se gestionó mediante la funcionalidad nativa de Google Colab, que registra automáticamente el historial de revisiones con marca de tiempo y autoría de cada cambio. Esto permitió consultar y restaurar versiones anteriores en cualquier momento durante el desarrollo, así como anclar revisiones específicas mediante la función "Save and Pin Revision" para preservar hitos relevantes del proyecto. La colaboración simultánea se realizó directamente sobre el notebook compartido en Google Drive, donde cada miembro del equipo pudo editar en tiempo real con identificación visual de cambios por autor.

3. DESCRIPCIÓN DE LOS DATOS

Al inicio de la realización nuestro trabajo disponemos de dos datasets diferentes, uno que hace referencia a los detenidos al comenzar el estudio de COMPAS (compass_score_raw) y otro dataset que es tomado dos años después (compass_score_two_years), donde se ve quién ha reincidido una vez acabado este periodo. No tienen la misma estructura, ni el mismo número de datos, ni siquiera coinciden todos los individuos en ambos datasets. Esta última afirmación hace que el estudio se limite y no puedan cruzarse datos de ambos datasets y adquirir conclusiones estadísticamente válidas. Por lo que nos vemos obligados a trabajar cada dataset por separado, aprovechando cada uno para sacar conclusiones diferentes.

3.1. EXPLORACIÓN INICIAL

3.1.1. compass_score_raw

El dataset está conformado por:

- 60.843 filas (3 filas por cada detención)
- 28 columnas, cuya forma de estar recogidos los datos eran las siguientes:

Person_ID	int64
AssessmentID	int64
Case_ID	int64
Agency_Text	object
LastName	object
FirstName	object
MiddleName	object
Sex_Code_Text	object
Ethnic_Code_Text	object
DateOfBirth	object
ScaleSet_ID	int64
ScaleSet	object
AssessmentReason	object
Language	object
LegalStatus	object
CustodyStatus	object
MaritalStatus	object
Screening_Date	object
RecSupervisionLevel	int64
RecSupervisionLevelText	object
Scale_ID	int64
DisplayText	object
RawScore	float64
DecileScore	int64
ScoreText	object

AssessmentType	object
IsCompleted	int64
IsDeleted	int64

Leyenda de las columnas:

Person_ID / Case_ID / AssessmentID	Identificadores únicos para el individuo, el caso judicial y la evaluación específica.
LastName / FirstName / MiddleName	Datos personales del individuo.
Agency_Text	Nombre de la agencia o condado donde se realizó la evaluación.
IsCompleted / IsDeleted	Indicadores binarios sobre el estado de la evaluación en la base de datos.

- Variables Demográficas y Perfil del Individuo: Son las variables que describen al sujeto evaluado. Aquí reside el núcleo del análisis de sesgos.

Sex_Code_Text	Género del individuo.
Ethnic_Code_Text	Etnia
DateOfBirth	Fecha de nacimiento, utilizada para calcular la edad actual en el momento del arresto.
MaritalStatus	Estado civil del individuo.
Language	Idioma principal del evaluado.

- Variables de Contexto Judicial y Supervisión: Información relativa a la situación legal del individuo en el momento de la evaluación.

LegalStatus	Estatus legal
CustodyStatus	Tipo de custodia en la que se encuentra
AssessmentReason	Motivo por el cual se realiza la evaluación
Screening_Date	Fecha en la que se realizó la entrevista y el test COMPAS

- Puntuaciones del Algoritmo COMPAS (Outputs): Estas variables representan la salida del algoritmo original que queremos auditar.

RawScore	Puntuación bruta calculada por el algoritmo.
DecileScore	La puntuación convertida a una escala de 1 a 10 (donde 1 es riesgo mínimo y 10 riesgo máximo).
ScoreText	Categorización del riesgo en niveles (Bajo, Medio, Alto).
ScaleSet / Scale_ID / DisplayText	Indican qué tipo de escala se está midiendo ("Riesgo de Reincidencia" o "Riesgo de Violencia").
RecSupervisionLevel / RecSupervisionLevelText	Nivel de supervisión recomendado tras la evaluación.

El dataset no presenta nulos en ninguna de sus columnas, exceptuando en "MiddleName", la cual carece de utilidad analítica ya que es usual que ese dato no exista en muchos individuos de la muestra.

El siguiente paso fue buscar los valores únicos de las columnas, que van a ser la base para comenzar a hacer un estudio de la muestra.

Person_ID	18610
AssessmentID	20281
Case_ID	19530
Agency_Text	4
LastName	10896
FirstName	7225
MiddleName	1870
Sex_Code_Text	2
Ethnic_Code_Text	9
DateOfBirth	10382
ScaleSet_ID	2
ScaleSet	2
AssessmentReason	1
Language	2
LegalStatus	7
CustodyStatus	6
MaritalStatus	7
Screening_Date	705
RecSupervisionLevel	4
RecSupervisionLevelText	4
Scale_ID	3
DisplayText	3
RawScore	659

DecileScore	11
ScoreText	3
AssessmentType	2
IsCompleted	1
IsDeleted	1

Conocer los valores únicos nos hizo darnos cuenta de que, al no haber duplicados y que cada arresto de un individuo reportara 3 filas, había individuos en la muestra que habían sido detenidos más de una vez en ese mismo periodo, ya que “AssessmentID” si corresponde al recuento de la muestra.

3.1.2 compas-scores-two-years

Dataset que hace referencia a 2 años después de la toma de datos, para comprobar su reincidencia. Consta de:

- 7.214 filas
- 53 columnas, con el tipo de datos:

id	int64
name	object
first	object
last	object
compas_screening_date	object
sex	object
dob	object
age	int64
age_cat	object
race	object
juv_fel_count	int64
decile_score	int64
juv_misd_count	int64
juv_other_count	int64
priors_count	int64
days_b_screening_arrest	float64
c_jail_in	object
c_jail_out	object
c_case_number	object
c_offense_date	object
c_arrest_date	object
c_days_from_compas	float64
c_charge_degree	object
c_charge_desc	object
is_recid	int64
r_case_number	object
r_charge_degree	object

r_days_from_arrest	float64
r_offense_date	object
r_charge_desc	object
r_jail_in	object
r_jail_out	object
violent_recid	float64
is_violent_recid	Int64
vr_case_number	object
vr_charge_degree	object
vr_offense_date	object
vr_charge_desc	object
type_of_assessment	object
decile_score.1	int64
score_text	object
screening_date	object
v_type_of_assessment	object
v_decile_score	int64
v_score_text	object
v_screening_date	object
in_custody	object
out_custody	object
priors_count.1	int64
start	int64
end	int64
event	int64
two_year_recid	int64

Leyenda de las columnas:

- Información Demográfica y Básica

id / name / first / last	Identificadores únicos y nombres del individuo (utilizados para gestión de datos, no para el modelo).
sex / dob / age / age_cat	Género, fecha de nacimiento y edad. age_cat segmenta la edad en rangos (<25, 25-45, >45), lo cual es clave para detectar sesgos generacionales.
race	Etnia del individuo; variable protegida esencial para el estudio de equidad.

- Historial Criminal (Antecedentes)

juv_fel_count	Número de delitos graves (<i>felonies</i>) cometidos como menor de edad.
juv_misd_count	Número de delitos menores (<i>misdemeanors</i>) como menor.
juv_other_count	Otros tipos de cargos como menor.
priors_count / priors_count.1	Recuento total de antecedentes penales previos.

- Datos del Caso Actual (C-Case)

Hacen referencia al delito por el cual el individuo entró en el sistema al momento de la evaluación COMPAS.

c_jail_in / c_jail_out	Fechas de entrada y salida de prisión por el caso actual.
c_case_number / c_offense_date / c_arrest_date	Metadatos del caso, fecha del delito y fecha del arresto.
c_charge_degree	Gravedad del cargo ("F" para <i>felony</i> , "M" para <i>misdemeanor</i>).
c_charge_desc	Descripción textual del delito cometido.
days_b_screening_arrest / c_days_from_compas	Diferencia de días entre la evaluación y el arresto

- Variables de Reincidencia (R-Case y VR-Case)

Indican si el sujeto volvió a cometer un delito tras la evaluación.

is_recid	Variable binaria que indica si hubo reincidencia general.
two_year_recid	Variable objetivo (<i>target</i>) principal; indica si reincidió en el plazo de dos años.
r_case_number / r_offense_date / r_charge_desc	Detalles del nuevo delito cometido si hubo reincidencia.
is_violent_recid / violent_recid	Indica si la reincidencia fue de naturaleza violenta.

- Puntuaciones Originales de COMPAS

decile_score / score_text	Puntuación (1-10) y categoría (Low/Medium/High) del riesgo de reincidencia general según COMPAS.
v_decile_score / v_score_text	Puntuación y categoría específicas para el riesgo de reincidencia violenta.
v_type_of_assessment	Tipo de evaluación de violencia realizada.

- Variables de Análisis de Supervivencia

start / end / event	Variables utilizadas en estadística de supervivencia para medir el tiempo transcurrido hasta que ocurre el "evento" (la reincidencia).
---------------------	--

Porcentaje de nulos por columnas:

violent_recid	100.00
vr_charge_degree	88.65
vr_offense_date	88.65
vr_case_number	88.65
vr_charge_desc	88.65
c_arrest_date	84.24
r_jail_in	67.90
r_days_from_arrest	67.90
r_jail_out	67.90
r_charge_desc	52.69
r_case_number	51.89
r_charge_degree	51.89
r_offense_date	51.89
c_offense_date	16.07
days_b_screening_arrest	4.26

c_jail_in	4.26
c_jail_out	4.26
out_custody	3.27
in_custody	3.27
c_charge_desc	0.40
c_case_number	0.30
c_days_from_compas	0.30
priors_count	0.00
age	0.00
juv_other_count	0.00
race	0.00
juv_fel_count	0.00
decile_score	0.00
age_cat	0.00
dob	0.00
sex	0.00
last	0.00
id	0.00
name	0.00
first	0.00
compas_screening_date	0.00
juv_misd_count	0.00
is_violent_recid	0.00
c_charge_degree	0.00
is_recid	0.00
type_of_assessment	0.00
screening_date	0.00

v_type_of_assessment	0.00
decile_score.1	0.00
score_text	0.00
v_score_text	0.00
v_decile_score	0.00
v_screening_date	0.00
priors_count.1	0.00
start	0.00
end	0.00
event	0.00
two_year_recid	0.00

3.2. LIMPIEZA DE DATOS

Como antes hemos hecho referencia, al cruzar ambos datasets identificamos 1.437 personas (23,11% de la muestra) que aparecen en el dataset de ProPublica pero no tienen correspondencia en el dataset del Condado de Broward.

Aunque el volumen es significativo, no se recomienda eliminar estos registros por las siguientes razones:

- Es improbable que ProPublica haya fabricado registros: su metodología está documentada y su objetivo es estudiar la reincidencia a dos años, no expandir artificialmente la muestra.
- Algunas discrepancias pueden deberse a correcciones editoriales aplicadas por ProPublica (por ejemplo, nombres y apellidos transpuestos), que dificulten el cruce, pero no invaliden el registro.
- Revisar manualmente 1.437 casos no es uso eficiente del tiempo en esta fase del análisis.


La decisión tomada por el grupo es que ambos datasets se trabajarán en paralelo cuando sea necesario, ya que ambos serán útiles para propósitos distintos.

El dataset de ProPublica ("compass_score_two_years") se usará como fuente principal para el análisis de reincidencia a dos años, sin descartar los registros no coincidentes.

3.2.1. compass_score_raw


Dado el volumen del dataset y la imposibilidad de validar registros con el Condado de Broward, la estrategia adoptada es corregir los errores que afecten directamente al análisis, sin eliminar filas completas por errores parciales: un error en una columna no invalida el resto de la información del registro.

1. Comenzamos convirtiendo las columnas de fechas que eran de tipo “object” en “date” y “datetime”, respectivamente. (“DateOfBirth” y “Screening_Date”)
2. Seguimos con el tratamiento de datos en las etnias, donde se aprecia errores al imputar los nombres.




Aplicamos los siguientes cambios:

- “African-Am” pasa a formar parte de “African-American”.
- “Arabic” al ser tan poco representativa en la muestra se unirá a “Other”.
- “Oriental” se une a “Asian”.




3. El siguiente punto a tratar es la detección de edades sospechas y hacer suposiciones acerca de ellas.

Comenzamos con edades inverosímiles:



La decisión tomada por el grupo en este punto fue captar la muestra, basándonos en que los individuos deben estar en el siguiente rango de edad:

- Tienen una edad inferior a la esperanza de vida en EEUU para la fecha en la que se realizó el screening. (~77 años)
- Son mayores de edad en la fecha que se ha hecho el screening.




3.2.2. compass_score_two_years

1. Al igual que en el dataset anterior, se realizó un preprocesamiento de las variables temporales. En concreto, se identificaron las columnas correspondientes a fechas y marcas temporales y se transformaron a los tipos de datos adecuados (date y datetime) con el fin de garantizar su correcta manipulación y análisis posterior.
2. Se limpiaron columnas duplicadas “decile_score.1” y “priors_count.1”, ya que son duplicados exactos de “decile_score” y “priors_count”. Optamos por la eliminación de las columnas duplicadas para evitar ser redundantes, posibles ambigüedades en el análisis y mantener el dataset limpio.
3. Verificamos la caída de screening dates en 2013. Revisamos las fechas y vimos que la variable compas_screening_date en compas-scores-two-years.csv tiene una caída en julio de 2013. La comparamos con Screening_Date en el archivo compas_scores_raw.


La disminución de casos en julio de 2013 aparece en ambos datasets. Esto confirma que el fenómeno proviene de los datos originales del condado, no del procesamiento de ProPublica.

Como viene del origen de los datos, no tenemos forma de corregirlo. Es un error de fuente, así que asumiremos esta caída como algo que puede esperarse.

compas_score_two_years



compass_score_raw




4. Corrección del cutoff de dos años

En los datos de "compas_scores_two_years", se intenta recopilar el nivel de reincidencia de cada persona dentro de los dos años posteriores a su evaluación COMPAS. Por ello, debido a que el dataset se recopiló con datos de arrestos hasta el 1 de abril de 2016, se deben quitar los datos con screening date posterior al 1 de abril de 2014 (de lo contrario, no tienen dos años completos de observación disponibles.)


El problema metodológico principal identificado en el dataset de "compas_scores_two_years" de ProPublica es que:

- eliminó a los no reincidentes con compas_screening_date posterior al 1 de abril de 2014,
- pero mantuvieron reincidentes con screening dates posteriores a esa fecha, inflando artificialmente la tasa de reincidentes.



En los datos vemos que ProPublica hizo un cutoff de 2 años únicamente en los no reincidentes (es decir, únicamente eliminó a los no reincidentes después de esa fecha) pero mantuvo los reincidentes.

Por coherencia en los datos, optamos por eliminar de nuestro dataset a todos los reincidentes con "compass_screening_date" posterior al 1 de abril de 2014, para igualar el *cutoff* entre reincidentes y no reincidentes.





5. Error en edades: El dataset contiene como su persona de mayor edad a una nacida en el año 1919. Siguiendo la misma norma que con el anterior dataset, el rango de edad de la muestra será:
 - Tienen una edad inferior a la esperanza de vida en EEUU para la fecha en la que se realizó el screening. (~77 años)
 - Son mayores de edad en la fecha que se ha hecho el screening.
6. Duplicados: No existen duplicados en este dataset.


4. DETECCIÓN DE SESGOS

En este apartado tratamos de conocer mejor los datos, sacando hipótesis y en algunos casos conclusiones de ellos. Utilizamos métodos como estadísticos o gráficos para ayudar a una mejor comprensión de ellos.

En un principio nos centramos en conocer los perfiles de los detenidos y decidimos comenzar por el dataset “compass_score_raw”.

Comenzamos con unos gráficos que nos muestren como se distribuye la muestra, teniendo en cuenta variables demográficas como: Etnia, sexo o estado civil.






El dataset dispone de dos variables que puntúan a los individuos:


- “DecileScore”: Puntuación del 1 al 10 que se le da a un individuo en tres aspectos diferentes:
 - Riesgo de reincidir
 - Riesgo de violencia
 - Riesgo de no comparecer
 - “RawScore”: Puntaje de COMPAS para cuya obtención no es posible conocer las variables utilizadas.

En ambos casos, estudiamos el riesgo a reincidir. Comenzamos con el “DecileScore”, viendo su distribución a lo largo de las diferentes razas.



Se puede ver como la tendencia de los datos en todas las razas es descendiente a medida que el “DecileScore” sobre el riesgo de reincidencia aumenta, salvo en “African-American” que se mantiene constante a lo largo de la muestra.

Hacemos lo propio con el “RawScore”.



En el “RawScore” al riesgo de reincidencia, se ve como la campana se encuentra desplazada a la derecha en la raza “African-American” respecto a las demás.


Sacamos estadístico que respalden numéricamente las impresiones adquiridas en los anteriores gráficos:

	count	mean	std	min	25%	50%	75%	max
Ethnic_Code_Text								
African-American	7692.0	-0.375	0.729	-2.41	-0.890	-0.340	0.17	2.36
Asian	88.0	-1.045	0.670	-2.29	-1.552	-1.175	-0.59	0.68
Caucasian	5093.0	-0.738	0.697	-2.52	-1.240	-0.760	-0.27	1.69
Hispanic	2332.0	-0.854	0.673	-2.35	-1.340	-0.920	-0.41	1.69

Todos los estadísticos respaldan que la raza “African-American” tiene una puntuación superior en términos generales en los estadísticos que las siguientes razas mayoritarias. (“Caucasian” e “Hispanic”).

En este momento del estudio comenzamos a plantear la hipótesis de que el modelo estuviese penalizando de manera superior a los individuos de la raza “African-American” sobre las demás razas, por lo que el paso que continua es la búsqueda de las variables que hicieran crecer esos scores que otorgaba el modelo.


Sacamos la matriz de correlación de Pearson entre los “RawScore” que se les ha dado a los diferentes riesgos (de reincidir, violencia y no comparecer).



Interpretación:

- El riesgo de reincidir y riesgo de violencia está correlacionado en un 81,3%.
- El riesgo de reincidir y no comparecer lo está en un 47,7%.
- El riesgo de no comparecer y el de violencia en un 27,6%.

El resultado más interesante obtenido es la alta correlación entre el puntaje que COMPAS da al riesgo de reincidir y el que le da al riesgo de violencia. Estos resultados nos invitan a estudiar cómo se distribuyen los puntajes al riesgo de violencia, ya que sabemos que tienen un gran peso a la hora de declarar que un individuo vaya a reincidir o no.



Podemos observar como la raza “African-American” se encuentra desplazada a la derecha respecto a las demás razas, lo que significa que recibe puntajes superiores a las demás razas en cuanto a riesgo de violencia.

Estos puntajes son los recibidos en el momento de toma de datos de los individuos, la manera que tenemos de comprobar si estos puntajes están sesgados es comprobando la reincidencia violenta de los individuos. Esta variable se encuentra en el dataset “compass_score_two_years” que, aunque no sea exactamente la misma muestra de individuos, nos servirá para demostrar si realmente esa raza reincide violentamente, y proporcionalmente, por encima de las demás.

Para su comprobación realizamos la siguiente tabla:

	v_decile_score	two_year_recid	is_violent_recid	total_casos	brecha_violencia
race					
African-American	4.287816	0.426607	0.116086	3127	0.312696
Native American	4.285714	0.428571	0.142857	14	0.285714
Hispanic	2.912343	0.279070	0.073345	559	0.217889
Caucasian	2.839756	0.301692	0.072368	2128	0.211607
Other	2.755162	0.283186	0.088496	339	0.187021
Asian	2.250000	0.178571	0.107143	28	0.117857

Explicación:

- v_decile_score: Media de puntaje que da COMPAS al riesgo de reincidencia violenta por raza, pudiéndose interpretar como una probabilidad (Ej. African-American = 42,87% de probabilidad de reincidencia violenta).
- two_years_recid: Porcentaje de reincidencia por raza.
- is_violent_recid: porcentaje de reincidencia violenta por raza.
- total_casos: recuento de individuos registrados por raza.
- brecha_violencia: Diferencia entre la predicción que hace COMPAS a la reincidencia violenta (“v_decile_score”) y la reincidencia violenta real (“is_violent_recid”)

Se puede observar que el riesgo de reincidencia violenta está entre el 30% y 40% en los grupos mayoritarios, mientras la reincidencia violenta real es mucho más baja, situándose entre el 7% y el 11%.


En razas como “African-American”, el sistema le da un puntaje de riesgo de violencia de 4.28 (lo que podría interpretarse como un 42,8%), pero la reincidencia violenta es tan solo del 11,6%.

El modelo es alarmista respecto al riesgo de violencia en todas las razas, pero en “African-American” es muy grande la diferencia respecto a la realidad (este hecho sucede en “Native-American”, pero es una muestra muy pequeña para valorarla con fiabilidad)

Llama la atención como los dos siguientes grupos de etnias con mayor representación (“Caucasian”, “Hispanic”), después de “African-American”, tienen un puntaje de riesgo de violencia y brecha en el puntaje prácticamente idéntico, reafirmando más la distinción en el trato a la raza “African-American” donde reciben puntajes más altos y la brecha es mayor.

5. EVALUACIÓN DE LOS PUNTAJES DE COMPAS

Antes de continuar, pongamos como preámbulo la diferencia que existe entre la tasa de reincidencia entre los 2 grupos mayoritarios de muestra. (80%)



Este gráfico muestra que los acusados “African-American” presentan una tasa base de reincidencia a dos años del 42.7%, frente al 30.2% de los “Caucasian”. Con tasas base distintas y un único umbral de decisión, no es posible tener simultáneamente FPR (False Positive Rate) igual, FNR (False Negative Rate) igual y *precision* igual entre grupos (Chouldechova, 2017): cumplir uno de estos criterios implica necesariamente sacrificar los otros. Vale la pena tener esto en cuenta al interpretar las disparidades observadas en las distribuciones de error.

Continuemos con la evaluación.

Para evaluar los puntajes de COMPAS, nos enfocaremos en 3 métricas diferentes:

- AUC: Qué tan bien el modelo distingue entre reincidentes y no reincidentes, es decir, la probabilidad de que asigne mayor riesgo (determinado por el *decile_score*) a un reincidente, independientemente de cualquier umbral.
- Precision/Recall: La calidad de las decisiones binarias al aplicar un umbral: *precision* mide cuán fiable es la etiqueta de “high-risk”, mientras que *recall* qué proporción de reincidentes reales es correctamente identificada.
- Calibration: Si las probabilidades predichas por el modelo reflejan tasas reales de reincidencia, es decir, si un riesgo estimado es X% corresponde aproximadamente a una reincidencia de X%.

5.1. AUC

El AUC es área bajo la curva de característica operativa del receptor.


Para intentar determinar la capacidad del score de COMPAS (definido por el "decile_score") para "rankear" correctamente a las personas según su riesgo de reincidencia en dos años, utilizamos el AUC, definido en este caso como la probabilidad de que una persona reincidente reciba una puntuación más alta que una persona no reincidente.

El AUC (área bajo la curva ROC) mide la eficacia con la que un sistema de puntuación clasifica los casos positivos por encima de los negativos comparando todos los pares positivo-negativo y calculando la proporción de veces que el caso positivo recibe una puntuación más alta que el caso negativo, lo que equivale al área bajo la curva de la tasa de verdaderos positivos frente a la tasa de falsos positivos en todos los umbrales posibles.

- un caso positivo es una persona que fue detenida nuevamente en un plazo de dos años (two_year_recid = 1)
- un caso negativo es una persona que no fue detenida nuevamente en un plazo de dos años (two_year_recid = 0)

Para interpretar los valores del AUC, podemos seguir esta regla:

- 0.5 = Clasificación aleatoria, igual lanzar una moneda.
- 0.5-0.7 = Clasificación deficiente, no mucho mejor que lanzar una moneda al aire.
- 0.7-0.8 = Clasificación aceptable.
- 0.8-0.9 = Clasificación excelente.
- Sobre 0.9 = Clasificación sobresaliente.




Aquí, en general, se obtiene un AUC de 0.702, lo que significa que cuando se elige al azar a una persona que ha sido arrestada de nuevo en un plazo de dos años y a otra que no lo ha sido, la puntuación COMPAS asigna una puntuación de riesgo más alta a la persona detenida de nuevo en aproximadamente el 70,22 % de los casos.

En términos sencillos: COMPAS es mejor que el azar a la hora de clasificar a las personas por riesgo, pero la separación entre reincidentes y no reincidentes es solo moderada, con un solapamiento sustancial entre los dos grupos.

Una vez obtenidos resultados generales, vamos a ver como se comporta el modelo cuando segmentamos diferentes variables demográficas:

ETNIA




Al estratificar por etnia, los deciles de COMPAS muestran una capacidad discriminatoria comparable y más baja que el AUC general (0.702) para los grupos "African-American", "Caucasian", "Hispanic" y "Other" (AUC $\approx$ 0,65-0,70).

Los valores de AUC que observamos para los grupos "Asian" y "Native American", si bien son bastante altos, no deberían interpretarse como una mejora en el rendimiento predictivo, ya que estos grupos contienen muestras muy pequeñas ($n = 28$ y $n = 14$, respectivamente), lo que hace que las estimaciones sean estadísticamente inestables.


Por ello, el análisis se centra en los grupos "African-American" y "Caucasian", que representan el 85% de la población.

EDAD



Al estratificar por edad, el AUC dentro de cada grupo es inferior al AUC general (0.702), lo que indica que el “decile_score” de COMPAS discrimina peor cuando se evalúa por separado dentro de cada franja de edad. Esto sugiere que parte de la capacidad predictiva del score proviene precisamente de capturar diferencias entre grupos de edad, no solo dentro de ellos.

GÉNERO



Al estratificar por género, el AUC de “Male” (0.704) es prácticamente idéntico al AUC general (0.702), mientras que “Female” muestra un rendimiento ligeramente inferior (0.683). En ambos casos, la capacidad discriminadora es comparable entre grupos.

La similitud de los valores AUC entre los distintos indicadores demográficos (etnia, edad y género) indica un rendimiento global comparable de COMPAS. Sin embargo, esto no implica que los factores demográficos sean irrelevantes para las predicciones o las consecuencias del sistema.

Dado que el AUC es similar en todos los grupos, a continuación, examinamos si COMPAS produce diferentes tasas de error (falsos positivos y falsos negativos) entre grupos demográficos cuando se utiliza como regla de decisión.

Esto nos permitirá evaluar a cuántos reincidentes COMPAS detecta realmente, cuántos no reincidentes se les marca erróneamente, y donde se concentran los falsos positivos/negativos.

5.2. PRECISION/RECALL

Antes usamos AUC, que nos permitía responder a la pregunta "¿COMPAS clasifica de forma razonablemente correcta?". Pero COMPAS no se utiliza como herramienta de clasificación en la práctica. Se utiliza de la siguiente manera:

- Alto riesgo: supervisión más estricta/detención
- Bajo riesgo: libertad/indulgencia

Una matriz de confusión representa una tabla con dos filas y dos columnas que reporta el número de verdaderos positivos, falsos negativos, falsos positivos y verdaderos negativos, lo cual:

- Permite identificar patrones de error específicos por grupo demográfico
- Revela disparidades en falsos positivos/negativos que el AUC global no muestra


Es decir, una matriz de confusión muestra el éxito y el fracaso de COMPAS cuando sus puntuaciones de riesgo se convierten en decisiones reales, contando las clasificaciones correctas e incorrectas de alto y bajo riesgo.

- Verdadero positivo (TP): La persona fue arrestada nuevamente y COMPAS la etiquetó como de alto riesgo.
- Falso positivo (FP): La persona NO fue arrestada nuevamente, pero COMPAS la etiquetó como de alto riesgo.
- Verdadero negativo (TN): La persona NO fue arrestada nuevamente y COMPAS la etiquetó como de bajo riesgo.
- Falso negativo (FN): La persona SÍ fue arrestada nuevamente, pero COMPAS la etiquetó como de bajo riesgo.

NOTA


El umbral seleccionado para clasificar a un individuo como "de riesgo" es $\text{decile_score} \geq 5$, que corresponde a las categorías "Medium Risk" y "High Risk" definidas por el propio sistema COMPAS (scores 5-10). Esta decisión sigue la metodología empleada por ProPublica en su análisis original, lo que permite que los resultados de precisión, recall y FPR sean directamente comparables con los publicados en dicho estudio.

El umbral $\text{decile_score} \geq 5$ es una convención adoptada para comparabilidad con ProPublica, no una verdad objetiva del sistema; otros umbrales producirían resultados distintos.


MATRIZ DE CONFUSIÓN NORMALIZADA

La matriz de confusión muestra que, globalmente, COMPAS clasifica correctamente como bajo riesgo al 67.6% de los no reincidentes (TN: 43.2% del total), pero etiqueta erróneamente como "de riesgo" al 32.4% restante (FP: 20.7% del total). Por otro lado, deja sin identificar a cerca del 37% de las personas que sí reincidirán (FN: 13.5% del total). Este patrón refleja un perfil de decisión agresivo: el sistema comete más errores por exceso que por defecto y prefiere sobre clasificar el riesgo antes que dejarlo pasar.

Ahora veamos cómo se comparan los resultados entre poblaciones. Comencemos calculando la matriz de confusión de las poblaciones más representativas de la variable demográfica "race": "African-American" y "Caucasian".



Representación de lo que puede considerarse los errores de COMPAS en estas razas:



Recordemos que los deciles de COMPAS muestran una capacidad predictiva comparable y más baja que el AUC general (0.702) para los grupos "African-American" y "Caucasian" (0.69 y 0.68 respectivamente).


Sin embargo, comparando ambos grupos con el mismo umbral COMPAS (≥ 5 , Medium + High Risk), vemos que, mientras que las tasas de falsos negativos son relativamente bajas entre los acusados "African-American" y los acusados "Caucasian" (una diferencia de 2.8 puntos porcentuales: 11.9% vs 14.7%), los primeros experimentan tasas de falsos positivos sustancialmente más altas que los otros (9.3 puntos porcentuales: 25.7% vs 16.4%), lo que indica cargas de error desiguales a pesar de un rendimiento predictivo general comparable.

Esto, a su vez, puede ser señal de que exista un sesgo en cómo el puntaje de COMPAS se traduce en decisiones reales según el grupo racial. En este caso, si se busca igualdad predictiva, las tasas de falsos positivos deben ser similares entre grupos.

Nota: El porcentaje de falsos positivos citado anteriormente (25.7% para African-American, 16.4% para Caucasian) corresponde a la proporción de FP sobre el total de cada subpoblación. El FPR, utilizado más adelante, es una métrica distinta: $FPR = FP / (FP + TN)$, es decir, qué fracción de los no reincidentes es clasificada erróneamente

como "de riesgo". Para el análisis de equidad se emplea el FPR por ser independiente del tamaño relativo de cada grupo.

Usamos los datos anteriores para determinar la presión y recall:



Los resultados indican que, aunque COMPAS presenta una capacidad de clasificación similar entre los grupos “African-American” y “Caucasian” (AUC comparable), el desempeño del sistema difiere al aplicar un umbral ≥ 5 (Medium + High Risk). En particular, la etiqueta de riesgo presenta un recall sustancialmente mayor para los acusados “African-American” (0.72) que para los acusados “Caucasian” (0.51), quienes quedan sin identificar en casi la mitad de los casos de reincidencia real.

En otras palabras:

COMPAS aplica el umbral de forma mucho más agresiva con “African-American”: marca como “de riesgo” (sobre el decile 5) al 56% de ese grupo (1765 de 3127), frente al 32% del grupo “Caucasian” (677 de 2128). Esa agresividad produce un recall notablemente más alto, pero apenas mejora la precisión (0.54 vs 0.48). Dicho de otro modo, el sistema clasifica a muchos más “African-American” como “de riesgo” sin ganar apenas fiabilidad predictiva a cambio, lo que se traduce principalmente en más falsos positivos (804 de “African-American” contra 349 de “Caucasian”).

Es decir, el sistema no es igualmente estricto con ambos grupos bajo el mismo umbral numérico. Un “Caucasian” y un “African-American” con el mismo score reciben la misma etiqueta, pero la probabilidad real de reincidencia que hay detrás de ese score es distinta entre grupos, lo que produce estos resultados asimétricos.

Estas diferencias reflejan principalmente las disparidades en las tasas base de reincidencia y muestran que una capacidad predictiva similar en términos de AUC no garantiza un desempeño equivalente en términos de precisión y cobertura del riesgo cuando se aplica un umbral uniforme.

5.3. CALIBRATION


La calibration (calibración) permite responder a la siguiente pregunta: cuando el modelo predice una probabilidad de reincidencia del X%, ¿aproximadamente X% de esas personas reinciden realmente?

Por ejemplo, para todos los individuos con una predicción de probabilidad de reincidencia del 0.30 ¿30% reincide en dos años?

Un score está bien calibrado si cumple esta idea básica "Personas con mayor puntuación tienen, en promedio, mayor tasa real de reincidencia que personas con menor puntuación." Es porque personas con menor riesgo de reincidir (menor "decile_score") deberían, lógicamente, reincidir menos.

Nótese que un modelo puede ordenar bien a los individuos (es decir, que en scores más altos se vea más reincidencia) sin que los valores absolutos sean estrictamente fieles a la realidad.


Evaluemos esta métrica.



Para cada "decile_score", "tasa_observada" es la proporción real de personas que reinciden entre quienes tienen ese mismo score. Es decir, personas con mayor puntuación tienen, en promedio, mayor tasa real de reincidencia que personas con menor puntuación.

Los resultados muestran que el "decile_score" de COMPAS está bien calibrado en sentido ordinal, ya que valores más altos del score corresponden sistemáticamente a mayores tasas observadas de reincidencia, aunque esto no garantiza decisiones equitativas bajo un umbral común ("decile_score" ≥ 8 o "High risk")

Hagamos la calibration segmentándola por las razas mayoritarias:



La comparación de la tasa observada de reincidencia por decil y raza muestra que, para la mayoría de los niveles del score, “African-American” y “Caucasian” presentan tasas similares, lo que sugiere una calibración comparable dentro de cada grupo.

Las diferencias más pronunciadas aparecen en el decil superior, especialmente para el grupo “Caucasian”, donde el tamaño muestral es reducido (observar la tabla abajo) y la estimación es estadísticamente inestable, lo que sugiere ruido en los extremos más que una mala calibración sistemática.

En este contexto, las disparidades observadas en precisión y recall bajo un umbral fijo de alto riesgo no contradicen la buena calibración del score, sino que reflejan la interacción entre un sistema de puntuación ordinal bien calibrado y la aplicación de un umbral común en presencia de tasas base y distribuciones distintas entre grupos.

5.4. CONCLUSIÓN DE LA EVALUACIÓN

El análisis muestra que COMPAS presenta una capacidad de discriminación similar entre los grupos “African-American” y “Caucasian”, como indican los valores comparables de AUC. Asimismo, el estudio de calibration por deciles evidencia que el decile_score está bien calibrado en sentido ordinal y de forma consistente dentro de cada grupo, ya que niveles más altos del score corresponden sistemáticamente a mayores tasas observadas de reincidencia; las diferencias más pronunciadas aparecen únicamente en el decil superior, donde los tamaños muestrales son reducidos para “Caucasian” y la variabilidad es mayor.

No obstante, al aplicar un único umbral para clasificar a los individuos como de alto riesgo, surgen diferencias sustanciales en precisión y recall. En particular, COMPAS identifica una mayor proporción de reincidentes en el grupo “African-American”, mientras que en el grupo “Caucasian” el sistema presenta un recall considerablemente inferior, omitiendo a una parte relevante de los reincidentes.

Estas disparidades no contradicen la buena calibración ni la capacidad de ordenación del score, sino que reflejan la interacción entre un sistema bien calibrado, el uso de un criterio de decisión uniforme y la existencia de tasas base y distribuciones distintas entre grupos.

En conjunto, los resultados indican que una AUC similar y una calibration adecuada no garantizan un desempeño equivalente en términos de precision y recall. Estos resultados subrayan que la evaluación de sistemas de riesgo debe ir más allá de métricas globales como el AUC y considerar cómo los scores se traducen en decisiones operativas. En este contexto, resulta pertinente analizar si modelos alternativos, entrenados con variables transparentes, reproducen patrones similares en términos de calibration y precision/recall.

6. CREACIÓN DEL MODELO DE MACHINE LEARNING

Ahora, se entrenará un modelo de regresión logística con el objetivo de estimar la probabilidad de reincidencia a partir de las variables disponibles en el dataset COMPAS, y evaluamos su desempeño por raza.

La elección de este modelo responde a su carácter lineal e interpretable, lo que permite analizar de manera transparente la contribución de cada variable en la predicción y establecer una línea base metodológicamente sólida. Además, la regresión logística constituye un punto de referencia estándar en problemas de clasificación binaria, facilitando comparaciones posteriores con modelos más complejos.

6.1. Estructura

Tras la evaluación de COMPAS mediante AUC, precision/recall y calibration, se constató que el sistema presenta una capacidad de discriminación comparable entre grupos y una calibración adecuada del “decile_score”, pero que al aplicar un umbral común emergen diferencias relevantes en las métricas operativas. Esto plantea la necesidad de analizar si dichas disparidades son atribuibles al diseño específico de COMPAS o si, por el contrario, responden a características estructurales.

Con este objetivo, se propone entrenar varios modelos de regresión logística utilizando distintas combinaciones de variables consideradas aceptables (principalmente historial delictivo y otros factores relevantes) excluyendo explícitamente la variable raza.

Estos modelos se evaluarán mediante las mismas métricas (AUC, precision/recall y calibration) para permitir una comparación sistemática con COMPAS y analizar si las diferencias observadas persisten bajo un enfoque predictivo más simple y transparente.

6.2. Modelo original

6.2.1. Preparación del dataset

Preparamos los datos para el modelo de regresión logística.

- Nos quedamos solo con “age_cat”, “juv_fel_count”, “juv_misd_count”, “juv_other_count”, “priors_count”, “c_charge_degree”, “two_year_recid”, ya que el resto son variables irrelevantes, pueden causar data leakage (como las variables relevantes a la reincidencia, p. ej., “r_case_number”, “r_offense_date”, “r_days_from_arrest”), o son precisamente la variable que queremos retirar para controlarla en el modelo (“race”).
- También eliminamos “sex”, ya que es una variable que puede redundar en sesgos (esta vez de género). Como nuestra intención es evitar introducir sesgo, también la eliminamos.
- Hacemos “get_dummies” para convertir las variables categóricas en numéricas.

- Separamos el dataset entre “train” (80% de la muestra) y “test”(20% de la muestra).
- Estandarizamos variables con “StandardScaler”.

Antes de entrenar el modelo, estandarizamos las variables numéricas con “StandardScaler”. Las variables tienen escalas muy distintas: “priors_count” puede llegar a 30 o más, mientras que las variables dummy solo toman valores 0 o 1.

“LogisticRegression” penaliza los coeficientes en función de su tamaño numérico, lo que distorsionaría artificialmente el peso de las variables con mayor escala.

Estandarizar garantiza que todas contribuyan en igualdad de condiciones y que los coeficientes sean interpretables correctamente.

En palabras simples, “StandardScaler” hace que todas las variables sean comparables entre sí.


NOTA: “StandardScaler” se aplica únicamente a las variables numéricas (`juv\_fel\_count`, `juv\_misd\_count`, `juv\_other\_count` y `priors\_count`), ya que las variables dummy (`age\_cat` y `c\_charge\_degree`) ya están en escala 0-1 y escalarlas distorsionaría su interpretación sin aportar beneficio al modelo.

6.2.2. Entrenamiento del modelo

Una vez entrenado el modelo, exploremos los parámetros con sus coeficientes e intercept, así como sus odds ratios.

- Coeficiente (coefficient): Es el peso que el modelo le asigna a cada variable del dataset. Indica cuánto influye esa variable en la predicción final y en qué dirección (positiva o negativa). Por ejemplo, si el coeficiente de `priors\_count` es alto, significa que tener más antecedentes tiene un fuerte impacto en la predicción del modelo.
- Odds ratio (razón de probabilidades): Indica cuánto se multiplican las probabilidades de reincidencia cuando una variable aumenta en una unidad, manteniendo constantes las demás variables. Para las variables continuas (“priors_count”, “juv_fel_count”, “juv_misd_count”, “juv_other_count”), que han sido estandarizadas, el incremento de una unidad equivale a una desviación estándar, no a un caso adicional. Para las variables dummy (“age_cat”, “c_charge_degree”), la interpretación es directa: 0 o 1.
- Intercepto (intercept): Es el valor base de la predicción cuando todas las variables del modelo valen cero. Es el punto de partida del modelo antes de considerar cualquier variable. En la práctica, es un ajuste que permite al modelo ser más preciso, aunque ninguna variable tenga un valor real de cero.

Ahora, evaluamos los coeficientes odds ratio de cada variable para interpretar su impacto en la probabilidad de reincidencia, así como el intercepto. Asimismo, convertimos el intercepto a odds ratio y a probabilidad para facilitar la interpretación



¿Qué podemos interpretar de los coeficientes y odds ratios?

Según el modelo, pertenecer al grupo de edad menor de 25 años es el factor más asociado con la reincidencia (Odds Ratio = 2.08), seguido muy de cerca por el historial de delitos previos (Odds Ratio = 1.99, interpretado por desviación estándar dado que la variable fue estandarizada). Ambos factores tienen un peso prácticamente equivalente en el modelo.

Ser mayor de 45 años aparece como el principal factor protector (Odds Ratio = 0.51).

¿Y para el intercepto?

El intercepto corresponde al perfil de referencia abstracto del modelo:



Persona de 25–45 años, con delito grave (Felony) y con un historial criminal en la media del conjunto de entrenamiento. Para este perfil, el modelo estima una probabilidad base de reincidencia del 36.41%.

6.2.3. Comparación entre test y training, usando classification reports.

Un classification report es un resumen tabular del desempeño de un modelo de clasificación. Este produce estas métricas:

- Precision: De todos los casos que el modelo predijo como clase X, ¿cuántos realmente lo eran?
- Recall (también llamado sensibilidad o tasa de verdaderos positivos): De todos los casos que realmente son clase X, ¿cuántos detectó el modelo?
- F1-Score: La media armónica entre precision y recall. Sirve para tener un solo número que equilibre ambas métricas, especialmente útil cuando hay desbalance entre clases.
- Macro avg: El promedio simple de cada métrica entre las dos clases, sin importar cuántos casos tiene cada una.
- Weighted avg: El promedio ponderado por el número de casos (support) de cada clase.

- Accuracy: De todos los casos, ¿qué porcentaje clasificó correctamente? Esta es una métrica global.



¿Qué nos dicen estos datos?

Mirando el conjunto Test, nos dicen que el modelo se comporta de forma muy similar en entrenamiento y en test, por lo que no hay señales de sobreajuste: generaliza correctamente a datos nuevos. La accuracy y los F1-score son prácticamente iguales en ambos conjuntos, lo que indica estabilidad.

Sin embargo, también muestran que el modelo está detectando mucho mejor la clase mayoritaria (clase 0) que la minoritaria (clase 1). El recall de la clase 0 es alto (0.905), mientras que el de la clase 1 es bajo (alrededor de 0.297). Esto significa que el modelo está perdiendo muchos casos reales de la clase 1.


En resumen, el modelo es consistente y generaliza bien, pero está sesgado hacia la clase más frecuente y no está capturando adecuadamente la clase menos frecuente.

¿Cómo podemos enfrentar esto? Balanceando las clases para que el algoritmo penalice más los errores en la clase minoritaria y menos en la mayoritaria (es decir, cambia la función de coste durante el entrenamiento.) Para ello, usamos `"class_weight='balanced'"`

6.3. Modelo balanceado



Hagamos una segunda predicción de todo el conjunto, usando “class_weight='balanced'”.

Tras instanciar y entrenar el modelo, evaluamos los coeficientes odds ratio de cada variable para interpretar su impacto en la probabilidad de reincidencia, así como el intercepto. Después, convertimos el intercepto a odds ratio y a probabilidad para facilitar la interpretación.







Vemos que la relevancia de las diferentes variables en el modelo balanceado es casi idéntica a la del modelo anterior: el mismo orden, la misma dirección, y magnitudes muy similares.

Luego, hacemos un nuevo “classification_report” para el modelo de regresión logística en train y test, con el nuevo modelo balanceado.



6.4. Modelo original vs Modelo balanceado





¿Qué nos dicen estos datos?

Comparando los datos en el conjunto de Test, que es el que mide el rendimiento real del modelo sobre datos no vistos, el modelo balanceado mejora sustancialmente la detección de reincidentes reales: el recall de la clase 1 (reincidentes) pasa de 0.30 a 0.62, es decir, se duplica. Sin embargo, la precisión cae de 0.64 a 0.52, lo que indica un aumento considerable de falsos positivos. Es el intercambio esperado: más sensibilidad, menos precisión.

En resumen, el modelo sigue generalizando bien, pero aumenta la cantidad de personas que son denominadas como potenciales reincidentes sin serlo.

CONCLUSIÓN DE LA EVALUACIÓN DE AMBOS MODELOS

En relación con la predicción de reincidencia judicial, el modelo original es preferible porque minimiza los falsos positivos: cuando marca a alguien como "de riesgo", acierta el 64% de las veces, frente al 52% del modelo balanceado.

Esto quiere decir que el modelo balanceado marca incorrectamente como reincidentes a casi la mitad de las personas que etiqueta como "de riesgo" (precisión: 0.52), influyendo en decisiones que les negarían libertad condicional o aumentarían sus sentencias por crímenes que no cometerían.

El coste del modelo original es que detecta menos reincidentes reales (recall más bajo, de 0.30 frente a 0.62 del balanceado). Pero este error tiene una naturaleza distinta: significa que el modelo no interviene, y la persona recibe el trato por defecto del sistema judicial sin el peso adicional de una predicción adversa.

En derecho penal, donde la presunción de inocencia es fundamental, es preferible un modelo conservador que se equivoque menos al acusar, aunque eso signifique perder capacidad de detección. Un falso positivo en este contexto no es un error estadístico, es una injusticia concreta contra una persona identificable.

7. MODELO COMPAS VS NUESTRO MODELO

Como indicamos anteriormente, el modelo que utilizaremos para esta comparación es el modelo de regresión logística original (sin balanceo de clases), cuya elección se justifica en la sección 6.4 por su menor tasa de falsos positivos, más adecuada al contexto judicial.


Adicionalmente, la evaluación de ambos modelos se realizó sobre el mismo subconjunto de test de 1239 casos, lo que puede reducir la estabilidad estadística de las métricas, especialmente en grupos étnicos poco representados como "Asian" o "Native American".

7.1. AUC


El AUC mide la capacidad del modelo para ordenar correctamente. Es decir: probabilidad de que un reincidente tenga un score mayor que un no reincidente.

Como no tenemos un "Score" como en el caso de COMPAS (que tenía un "decile_score" asignado por su modelo), usaremos la probabilidad de reincidencia (calculado por el método "predict_proba").

NOTA: Es importante destacar que, para garantizar la comparabilidad, los resultados de rendimiento del modelo COMPAS (incluido el AUC) se recalculan sobre el mismo subconjunto de test que usa nuestro modelo (n=1239) para que la comparación sea válida.



Hacemos la comparativa por grupo étnico:




Nuestro modelo presenta una capacidad de discriminación general superior a COMPAS (AUC 0.708 vs 0.685), con una mejora de +0.023. Esta mejora se concentra en los grupos más representativos: “African-American” (+0.025), “Caucasian” (+0.051) e “Hispanic” (+0.041). “Native American” no tiene representación suficiente para calcular AUC.

Nota: El rendimiento inferior de nuestro modelo en los grupos “Other” y “Asian” debe interpretarse con cautela por dos razones:


- Primera, los tamaños muestrales en test son muy reducidos (“Other”: n=68, “Asian”: n=5), lo que hace que el AUC sea muy sensible a unos pocos casos y estadísticamente inestable.
- Segunda, si estos grupos están igualmente poco representados en el conjunto de entrenamiento, el modelo no habrá aprendido bien sus patrones específicos de reincidencia, lo que puede explicar un rendimiento inferior al de COMPAS, que fue entrenado con un volumen de datos históricamente mayor.

Ambas razones son suposiciones plausibles, no conclusiones verificadas con los datos disponibles.

7.2. CALIBRATION




Esto insinúa que nuestro modelo está bien calibrado: las probabilidades predichas se ajustan estrechamente a la diagonal, con ligera inestabilidad solo en el tramo alto. Debido a que la calibration curve de nuestro modelo se tiene ruido en la probabilidad más elevada, grafiquemos la distribución de probabilidades predichas por nuestro modelo en el conjunto de test.



Podemos ver que la mayoría de los casos se concentran en probabilidades bajas y medias (entre aproximadamente 0.15 y 0.55), con pocos casos por encima de 0.7. Esto

explica la mayor inestabilidad de las curvas de calibración de nuestro modelo en el rango alto.


COMPARACIÓN DE CALIBRATION DE COMPAS CON NUESTRO MODELO



Conviene recordar que la buena calibración ordinal de COMPAS (demostrada en la sección anterior, donde scores más altos corresponden sistemáticamente a mayores tasas de reincidencia) no implica que sus probabilidades estén bien calibradas en sentido absoluto. Una cosa es que el ranking sea correcto; otra, que el valor numérico del score refleje fielmente la probabilidad real. Es precisamente esta segunda dimensión la que permite comparar ambos modelos en la sección 7.3.

- COMPAS sobrestima sistemáticamente el riesgo a partir de scores medios-altos: la curva se aplana por debajo de la diagonal desde 0.4 en adelante, lo que significa que cuando COMPAS asigna scores altos, la tasa real de reincidencia es menor de lo que el score sugiere.
- Nuestro modelo sigue la diagonal más de cerca en el rango 0.2-0.6, lo que indica mejor calibración en la zona donde se concentra la mayoría de los casos.

COMPARACIÓN DEL MODELO COMPAS Y EL NUESTRO SOBRE LA CALIBRATION POR RAZAS




- En COMPAS ambos grupos se sitúan por debajo de la diagonal a lo largo de casi todo el rango, lo que indica que el sistema tiende a sobreestimar el riesgo para ambas poblaciones. “African-American” se sitúa sistemáticamente por encima de “Caucasian”, lo que sugiere que para un mismo score, los “African-American” reinciden algo más que los “Caucasian”, pero ambos por debajo de lo que el score predice.
- Nuestro modelo presenta un comportamiento comparable entre grupos en el rango aproximado de 0.15-0.55, donde se concentra la mayoría de los casos (como pudimos comprobar más arriba). Por encima de 0.6, ambas curvas divergen con alta inestabilidad, lo que refleja el reducido tamaño muestral en ese tramo y no una mala calibración estructural.

En conjunto, ninguno de los dos modelos muestra una diferencia sistemática de calibración entre grupos raciales en el rango donde los datos son suficientes.

7.3. RESTO DE MÉTRICAS

Cómo hicimos anteriormente con el AUC, para que la comparación sea válida, COMPAS debe evaluarse sobre exactamente los mismos casos que nuestro modelo.

Evaluemos el accuracy, precision, recall y F1 de ambos modelos:



Nuestro modelo supera a COMPAS en accuracy (0.69 vs 0.65) y precision (0.64 vs 0.51): cuando etiqueta a alguien como "de riesgo", acierta más frecuentemente, lo que se traduce en menos personas marcadas injustamente como potenciales reincidentes.

El recall es inferior (0.30 vs 0.58), lo que refleja una elección de diseño deliberada: al ser más conservador en la clasificación de riesgo, reduce los falsos positivos a costa de


detectar menos reincidentes. En un contexto judicial, donde un falso positivo supone penalizar preventivamente a una persona que no reincidiría, esta elección es coherente con el principio de minimizar el daño injustificado.

La métrica que permite comparar ambos modelos sin el efecto del umbral es el AUC, donde nuestro modelo supera a COMPAS (0.708 vs 0.685).

7.4. Evaluación de métricas globales de equidad por raza

Evaluemos el FPR por raza de COMPAS y de nuestro modelo.

El FPR (False Positive Rate) mide la proporción de personas que no reincidieron, pero fueron etiquetadas erróneamente como de riesgo por el modelo.




Nuestro modelo reduce drásticamente el FPR absoluto en ambos grupos: de 0.429 a 0.129 en “African-American”, y de 0.221 a 0.067 en “Caucasian” (una reducción del 70% en ambos casos).

En términos concretos, COMPAS etiquetaba incorrectamente como “de riesgo” al 42.86% de los acusados “African-American” que nunca reincidirían; nuestro modelo reduce esa cifra al 12.91%. Para los acusados “Caucasian”, se repite esta tendencia con una reducción del 22.11% al 6.67%.


Es una mejora muy sustancial en términos de daño absoluto sobre personas concretas.



Sin embargo, veamos la disparidad relativa entre grupos (es decir, la proporción de FPR entre ambas razas por cada modelo).



La disparidad relativa entre grupos es prácticamente idéntica en ambos modelos (1.939 vs 1.937), un acusado “African-American” sin reincidencia tiene casi el doble de probabilidad de ser etiquetado como de riesgo que uno “Caucasian” equivalente, independientemente del modelo utilizado. Nuestro modelo reduce el daño absoluto de forma sustancial, pero no resuelve la desigualdad estructural entre grupos.

Extraigamos el resto de las métricas entre “African-American” y “Caucasian” para ver cómo se comportan.






Nuestro modelo mejora la precision en ambos grupos (“African-American”: 0.68 vs 0.54; “Caucasian”: 0.59 vs 0.46), a costa de un recall más bajo. Esto es coherente con la elección de diseño: un modelo más conservador que se equivoca menos al acusar, aunque detecte menos reincidentes reales. El F1, que pondera ambas métricas, es inferior al de COMPAS en los dos grupos, lo que refleja precisamente ese intercambio.

7.5. Equilized Odds gap

El Equalized Odds gap mide cuánto difiere el modelo entre “African-American” y “Caucasian” en dos tasas de error:

- Recall (TPR): cuántos reincidentes reales detecta correctamente.
- FPR: cuántos no reincidentes clasifica erróneamente como reincidentes.

El indicador devuelve la diferencia más desfavorable entre grupos en estas dos tasas. Cuanto más alto, más desigualmente distribuye el modelo sus errores entre razas. Cuanto más cercano a cero, más equivalente es el trato entre grupos en términos de errores predictivos.



Nuestro modelo reduce el “Equalized Odds gap” de 0.208 a 0.131, lo que indica que distribuye sus errores de forma más equitativa entre grupos raciales que COMPAS.

Sin embargo, un gap de 0.131 sigue siendo sustancial: el modelo no trata a ambos grupos de forma equivalente, solo lo hace menos desigual.

8. DASHBOARD DE MONITORIZACIÓN

Para facilitar la comunicación de los resultados y permitir la exploración interactiva de las métricas obtenidas, se desarrolló un dashboard en **Looker Studio** conectado a **Google BigQuery** como fuente de datos.

8.1. Arquitectura y pipeline de datos

El proceso de construcción del dashboard siguió los siguientes pasos:

1. **Exportación de datos desde el notebook:** Una vez completado el análisis en Python, se exportaron los conjuntos de datos relevantes a formato CSV. Estos incluyen las predicciones de ambos modelos (COMPAS y nuestro modelo de regresión logística), los valores reales de reincidencia, las métricas por grupo racial y los datos necesarios para construir las curvas de calibración.
2. **Carga en Google BigQuery:** Los ficheros CSV se cargaron en BigQuery como tablas. En los casos en que fue necesario aplicar transformaciones o correcciones menores sobre los datos (como recálculos o modificación de nombres) estas se realizaron directamente mediante consultas SQL en BigQuery.
3. **Conexión Looker Studio - BigQuery:** Looker Studio se conectó a las tablas de BigQuery como fuente de datos.

8.2. Contenido del dashboard

El dashboard se compone de dos páginas. Ambas páginas incluyen métricas orientativas sobre la población analizada: total de población, tasa de reincidencia real, proporción clasificada como "de riesgo" por COMPAS ($\text{decile_score} \geq 5$) y proporción clasificada como positiva por nuestro modelo (umbral de probabilidad $\geq 0,5$). Estas cifras son tasas de clasificación bajo sus respectivos umbrales, no probabilidades medias estimadas.



Página 1: Métricas de rendimiento y equidad (interactiva).

Permite comparar COMPAS y nuestro modelo en las métricas globales (accuracy, precision, recall, F1, FPR y disparidad relativa de FPR entre African-American y Caucasian). Incorpora dos controles: uno para seleccionar la segmentación (global o por raza) y otro para filtrar por grupo racial específico. Las métricas se recalculan dinámicamente según la selección, lo que permite explorar de forma granular cómo se comporta cada modelo frente a distintas subpoblaciones.

Página 2: rendimiento y calibración (estática).

Muestra la distribución de TP, TN, FP y FN tanto a nivel global como desglosada por raza para cada modelo, el AUC global y por grupo racial, y las curvas de calibración global y segmentadas por raza para COMPAS y nuestro modelo. Esta página permite verificar visualmente si los modelos sobre o subestiman el riesgo en distintos tramos de probabilidad.

Nota metodológica: Para poder representar ambas curvas de calibración en el mismo eje X, las probabilidades continuas de nuestro modelo (rango 0–1) se normalizaron a escala 1–10 multiplicando por 10 y redondeando al entero más cercano, equiparándolas así a los deciles de COMPAS. Este rebinning se realizó exclusivamente en Looker Studio con fines de visualización; los valores reales de tasa observada de reincidencia que sustentan cada punto son idénticos a los calculados en el notebook. La comparación es, por tanto, orientativa: ambas escalas no son conceptualmente equivalentes, ya que COMPAS produce deciles ordinales discretos mientras que nuestro modelo produce probabilidades continuas.

9. CONCLUSIONES Y REFLEXIONES

Resultados numéricos entre modelos

Nuestro modelo supera a COMPAS en las métricas globales de rendimiento: accuracy (0.69 vs 0.65), precision (0.64 vs 0.51) y AUC (0.708 vs 0.685). El AUC es la comparación más robusta al ser independiente del umbral de clasificación elegido.

El F1 global es inferior en nuestro modelo, consecuencia directa del recall más bajo.

Nuestro modelo mejora la precision en ambos grupos raciales respecto a COMPAS:

- "African-American": 0.68 vs 0.54 (+0.14)
- "Caucasian": 0.59 vs 0.46 (+0.13)

El recall es inferior en ambos grupos ("African-American": 0.36 vs 0.67; "Caucasian": 0.23 vs 0.47), lo que refleja la elección de diseño deliberada de priorizar la reducción de falsos positivos sobre la detección exhaustiva.

En términos de daño absoluto, la reducción del FPR es sustancial: de 42.86% a 12.91% en "African-American", y de 22.11% a 6.67% en "Caucasian". COMPAS etiquetaba incorrectamente como "de riesgo" a casi 1 de cada 2 acusados "African-American" que nunca reincidirían; nuestro modelo reduce esa cifra a poco más de 1 de cada 8.

Sin embargo, la disparidad relativa de FPR entre grupos es prácticamente idéntica en ambos modelos (1.937 vs 1.939): un acusado "African-American" sin reincidencia tiene casi el doble de probabilidad de ser etiquetado como "de riesgo" que uno "Caucasian" equivalente, independientemente del modelo utilizado.

Nuestro modelo reduce el "Equalized Odds gap" de 0.208 a 0.131 (una mejora del 37%), distribuyendo sus errores de forma más equitativa entre razas, aunque un gap de 0.131 sigue siendo sustancial.

En síntesis, nuestro modelo es más preciso y menos dañino en términos absolutos, pero no elimina la disparidad estructural entre grupos. Representa una mejora en eficacia y una reducción parcial en inequidad, no una solución al problema de fondo.

Limitaciones

El presente trabajo presenta las siguientes limitaciones que conviene tener en cuenta al interpretar los resultados:

- En primer lugar, nuestro modelo se basa en regresión logística, un algoritmo interpretable, pero de capacidad predictiva limitada. Modelos más complejos podrían capturar patrones no lineales relevantes, aunque a costa de transparencia.

- En segundo lugar, la evaluación de ambos modelos se realizó sobre un subconjunto de test de 1239 casos, lo que podría reducir la estabilidad estadística de las métricas, especialmente en grupos con baja representación (como "Asian" o "Native American").
- En tercer lugar, no fue posible validar los registros del dataset de ProPublica contra los datos originales del condado de Broward, lo que impidió resolver algunas discrepancias identificadas en el cruce entre los datasets "compass_score_raw" y "compass_score_two_years".

Reflexión crítica: implicaciones del uso de modelos predictivos en decisiones judiciales

Los resultados anteriores permiten una conclusión técnica clara: nuestro modelo mejora la precisión de COMPAS y reduce parcialmente la disparidad en errores entre grupos raciales (demostrado por el "Equalized Odds gap" de 0.208 a 0.131). Sin embargo, esa mejora no debe interpretarse como una justificación para el uso de este tipo de herramientas en decisiones judiciales.

La disparidad relativa de FPR entre grupos es prácticamente idéntica en ambos modelos (1.939 vs 1.937): un acusado "African-American" sin antecedentes de reincidencia tiene casi el doble de probabilidad de ser etiquetado como "de riesgo" que uno "Caucasian" equivalente, independientemente del modelo utilizado.

La disparidad estructural persiste porque las variables utilizadas (historial de arrestos, delitos juveniles) pueden ser en sí mismas el resultado de un sistema que ha actuado históricamente de forma desigual (como discute Chouldechova en su paper *"Fair prediction with disparate impact: A study of bias in recidivism prediction instruments"*)

Cualquier modelo entrenado sobre esos datos hereda esa desigualdad: no existe una solución puramente técnica a un problema fundamentalmente estructural.

La comparación relevante no es entre un modelo sesgado y la ausencia de sesgo, sino entre un modelo sesgado y el juicio humano, que tampoco es neutral. Ya que el juicio humano puede estar también sesgado, el riesgo específico de formalizar estos modelos es que escalan y legitiman el sesgo dándole apariencia de objetividad cuantitativa (como explica Angwin et al en *"Machine Bias There's software used across the country to predict future criminals. And it's biased against blacks"*)

En el caso de herramientas propietarias como COMPAS, impiden que el acusado pueda conocer o impugnar los criterios que determinaron su puntuación (como sugieren Rudin et al y Angwin et al en *"The age of secrecy and unfairness in recidivism prediction"* y *"Machine Bias There's software used across the country to predict future criminals. And it's biased against blacks"* respectivamente)

Más allá de los resultados técnicos, y como posición normativa derivada del análisis, si se acepta algún papel para estas herramientas, debería limitarse a una señal secundaria, auditada públicamente, y siempre subordinada al criterio del juez. El objetivo de reducir la reincidencia no puede alcanzarse a costa de sistematizar la injusticia hacia los grupos más vulnerables del sistema.

10. BIBLIOGRAFÍA

- Angwin, J., Larson, J., Mattu, S., & Kirchner, L. (23 de mayo de 2016). *Machine Bias: There's software used across the country to predict future criminals. And it's biased against blacks*. ProPublica. <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>
- Corbett-Davies, S., Pierson, E., Feller, A., Goel, S., & Huq, A. (2017). Algorithmic decision making and the cost of fairness. *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 797–806. <https://doi.org/10.1145/3097983.3098095>
- Larson, J., Mattu, S., Kirchner, L., & Angwin, J. (2016). *Compas-analysis* [Repositorio de software]. GitHub. <https://github.com/propublica/compas-analysis>
- Chouldechova 2017 "Fair prediction with disparate impact: A study of bias in recidivism prediction instruments". <https://arxiv.org/pdf/1610.07524>
- Rudin et al. 2019 "The age of secrecy and unfairness in recidivism prediction" <https://arxiv.org/pdf/1811.00731>
- **Fairlearn**. Bird, S., Dudík, M., Edgar, R., Horn, B., Lutz, R., Milan, V., ... & Walker, H. (2020). *Fairlearn: A toolkit for assessing and improving fairness in AI*. Microsoft Research. <https://www.microsoft.com/en-us/research/publication/fairlearn-a-toolkit-for-assessing-and-improving-fairness-in-ai/>

- **Scikit-learn.** Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

- **Pandas.** McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 445, 51-56.

- **Matplotlib.** Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95. <https://doi.org/10.1109/MCSE.2007.55>